

LAPORAN TUGAS MACHINE LEARNING

CHAPTER 3

UNSUPERVISED LEARNING AND PREPROCESSING

Implementasi Preprocessing, Reduksi Dimensi, Manifold Learning, Clustering,
dan Evaluasi



Disusun oleh:

Ariel Tiansyahrullah G1A024011

Mata Kuliah :

Machine Learning

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

DAFTAR ISI

BAB I PENDAHULUAN	3
1.1 Latar Belakang.....	3
1.2 Tujuan Pengerjaan.....	3
1.3 Struktur Repository	3
1.4 Alur Eksperimen.....	4
BAB II PREPROCESSING DAN REDUKSI DIMENSI	5
2.1 Preprocessing dan Scaling.....	5
2.2 Perbandingan Metode Scaling.....	5
2.3 Dampak Scaling terhadap SVC	6
2.4 Principal Component Analysis	7
2.5 Non-Negative Matrix Factorization	8
2.6 t-SNE	9
BAB III CLUSTERING DAN EVALUASI	10
3.1 k-Means	10
3.2 Agglomerative Clustering	11
3.3 DBSCAN	12
3.4 Evaluasi ARI dan Silhouette	13
BAB IV IMPLEMENTASI REPOSITORY DAN ANALISIS	15
4.1 Organisasi Program	15
4.2 Hasil Utama	15
4.3 Analisis Kritis.....	15
BAB V PENUTUP	17
5.1 Kesimpulan.....	17
5.2 Saran.....	17
DAFTAR PUSTAKA	18

BAB I

PENDAHULUAN

1.1 Latar Belakang

Machine learning tidak selalu bekerja dengan data yang telah memiliki label. Dalam unsupervised learning, pola dicari dari struktur data itu sendiri, misalnya dengan mengelompokkan objek yang memiliki kemiripan atau dengan mereduksi banyak fitur menjadi representasi yang lebih ringkas. Chapter 3 yang diimplementasikan pada repository TugasML_CH3 menempatkan preprocessing sebagai bagian penting karena algoritma yang berbasis jarak, variansi, atau kerapatan dapat memberikan hasil yang berbeda apabila setiap fitur memiliki skala yang sangat tidak seimbang.

Repository ini menggabungkan beberapa tahapan yang saling berhubungan. Scaling digunakan untuk menyetarakan rentang fitur, PCA dan NMF digunakan untuk membangun representasi baru, t-SNE digunakan untuk memvisualisasikan struktur lokal data berdimensi tinggi, sedangkan k-Means, Agglomerative Clustering, dan DBSCAN digunakan untuk mempelajari bentuk-bentuk pengelompokan yang berbeda. Dengan susunan tersebut, tugas tidak hanya memperkenalkan algoritma secara terpisah, tetapi juga menunjukkan bagaimana pemilihan representasi data memengaruhi proses analisis berikutnya.

1.2 Tujuan Pengerjaan

Pengerjaan Chapter 3 bertujuan memahami konsep preprocessing dan unsupervised learning melalui implementasi langsung menggunakan Python dan scikit-learn. Secara khusus, tugas ini digunakan untuk mempelajari perbedaan beberapa metode scaling, memahami prinsip reduksi dimensi dan ekstraksi fitur, membandingkan karakteristik berbagai algoritma clustering, serta mengevaluasi hasil pengelompokan menggunakan metrik yang sesuai. Hasil implementasi juga disusun agar dapat dijalankan melalui notebook interaktif maupun skrip Python mandiri.

1.3 Struktur Repository

Repository GitHub yang digunakan bernama TugasML_CH3. Di dalamnya terdapat empat berkas utama yang membagi fungsi dokumentasi,

eksperimen interaktif, program mandiri, dan konfigurasi visualisasi. Pembagian ini membuat materi lebih mudah ditelusuri karena notebook dapat digunakan untuk melihat proses dan output secara bertahap, sedangkan skrip Python dapat dipakai untuk menjalankan rangkaian demonstrasi secara langsung dari terminal.

Berkas	Fungsi Utama
03-unsupervised-learning.ipynb	Notebook utama yang memuat penjelasan, sel kode, visualisasi, dan output eksperimen Chapter 3.
chapter3_unsupervised_learning.py	Skrip mandiri yang merangkum preprocessing, PCA, NMF, t-SNE, clustering, serta evaluasi.
preamble.py	Konfigurasi NumPy, Pandas, Matplotlib, dan mglearn agar tampilan serta kompatibilitas lebih konsisten.
README.md	Dokumentasi struktur berkas, ringkasan materi, serta cara menjalankan notebook dan skrip.

1.4 Alur Eksperimen

Alur eksperimen dimulai dari pemuatan dataset, dilanjutkan dengan penyesuaian skala atau pembentukan representasi baru, kemudian penerapan algoritma yang sesuai dengan tujuan analisis. Dataset Breast Cancer digunakan untuk memperlihatkan dampak scaling dan PCA, dataset Digits digunakan pada t-SNE, data sintetis digunakan pada NMF dan beberapa contoh clustering, sedangkan dataset Two Moons digunakan untuk membandingkan kualitas k-Means, Agglomerative Clustering, dan DBSCAN. Pada tahap akhir, hasil clustering dibandingkan melalui ARI dan Silhouette Score sehingga perbedaan antara kecocokan terhadap label acuan dan kekompakan bentuk klaster dapat diamati.

BAB II


PREPROCESSING DAN REDUKSI DIMENSI

2.1 Preprocessing dan Scaling

Preprocessing pada repository berfungsi mengubah representasi numerik fitur sebelum data diberikan kepada algoritma. Langkah ini penting karena perbedaan satuan dapat membuat fitur dengan rentang besar mendominasi perhitungan jarak atau fungsi objektif. Kode menggunakan empat pendekatan, yaitu StandardScaler, MinMaxScaler, RobustScaler, dan Normalizer. Masing-masing tidak menghasilkan representasi yang sama, sehingga pemilihannya harus disesuaikan dengan sifat data dan kebutuhan model.

2.2 Perbandingan Metode Scaling

Metode	Prinsip	Karakteristik
StandardScaler	Menggeser rata-rata ke sekitar 0 dan menskalakan berdasarkan simpangan baku.	Cocok ketika perbandingan antarfitur perlu dibuat dalam skala statistik yang serupa.
MinMaxScaler	Memetakan nilai setiap fitur ke rentang 0 sampai 1.	Menjaga urutan relatif data, tetapi cukup sensitif terhadap nilai ekstrem.
RobustScaler	Menggunakan median dan rentang antarkuartil.	Lebih tahan terhadap outlier dibanding scaler yang bergantung pada minimum, maksimum, atau rata-rata.
Normalizer	Menormalkan setiap sampel sehingga panjang vektornya menjadi 1.	Berbeda dari scaler lain karena normalisasi dilakukan per baris/sampel, bukan per fitur.



Gambar 1. Visualisasi ulang perbedaan skala data sebelum dan sesudah beberapa metode preprocessing.

2.3 Dampak Scaling terhadap SVC

Walaupun fokus Chapter 3 adalah unsupervised learning, repository menggunakan Support Vector Classifier (SVC) pada dataset Breast Cancer untuk menunjukkan bahwa preprocessing juga berpengaruh besar pada algoritma supervised yang sensitif terhadap skala. Pola kode yang digunakan sudah benar dari sisi pemisahan data: scaler dipelajari hanya dari data latih melalui `fit()`, kemudian `transform()` diterapkan pada data latih dan data uji. Cara ini mencegah informasi statistik dari data uji masuk ke tahap pelatihan.


README repository menekankan contoh peningkatan akurasi dari sekitar 63% sebelum scaling menjadi sekitar 97% setelah scaling. Nilai tepat dapat berubah ketika kode dijalankan dengan versi scikit-learn yang berbeda karena parameter bawaan beberapa estimator pernah mengalami perubahan. Namun makna eksperimennya tetap sama: ketika fitur berada pada rentang yang sangat berbeda, model berbasis jarak atau margin dapat bekerja kurang optimal, sedangkan scaling membuat kontribusi setiap fitur menjadi lebih seimbang.

Tahap	Proses pada Kode	Makna
1	Membagi data menjadi train dan test.	Menjaga evaluasi dilakukan pada data yang tidak dipakai untuk melatih model.
2	Scaler di-fit pada X_train.	Statistik transformasi hanya berasal dari data latih.
3	X_train dan X_test ditransformasikan.	Kedua bagian data berada pada ruang skala yang sama.
4	SVC dilatih dan diuji kembali.	Perubahan performa dapat dibandingkan sebelum dan sesudah scaling.

Eksperimen ini sekaligus memberikan dasar untuk bagian clustering. k-Means dan DBSCAN sama-sama menggunakan konsep jarak, sehingga preprocessing dapat mengubah struktur klaster yang terdeteksi. Karena itu, pada dataset Two Moons di bagian evaluasi, StandardScaler diterapkan terlebih dahulu sebelum algoritma clustering dibandingkan.

2.4 Principal Component Analysis (PCA)

PCA digunakan untuk mereduksi jumlah fitur dengan mencari arah baru yang mempertahankan variasi data sebesar mungkin. Pada repository, dataset Breast Cancer yang memiliki 30 fitur terlebih dahulu distandardisasi, kemudian direduksi menjadi dua principal components menggunakan $\text{PCA}(n_components=2)$. Hasil transformasi mengubah bentuk data dari 569×30 menjadi 569×2 , sehingga data yang sebelumnya sulit divisualisasikan dapat ditempatkan pada bidang dua dimensi.



Gambar 2. Proyeksi PCA dataset Breast Cancer dari 30 fitur menjadi dua komponen utama.


Pada visualisasi ulang dengan dataset dan prosedur yang sama, komponen pertama menjelaskan sekitar 44,3% variansi dan komponen kedua sekitar 19,0%, sehingga dua komponen awal mempertahankan sekitar 63,2% variasi data. Warna kelas pada gambar hanya digunakan setelah proses PCA untuk membantu membaca pola; label tidak dipakai ketika PCA membentuk komponen. Hal ini sesuai dengan sifat PCA sebagai teknik unsupervised yang bekerja berdasarkan struktur variansi pada fitur.

2.5 Non-Negative Matrix Factorization (NMF)

NMF membentuk representasi data sebagai kombinasi komponen yang seluruh nilainya tidak negatif. Pada skrip repository, sinyal sintetis dibentuk terlebih dahulu kemudian dicampur ke dalam banyak dimensi. NMF dengan tiga komponen digunakan untuk mencoba menemukan kembali pola dasar penyusun sinyal tersebut, sedangkan PCA dipakai sebagai pembanding. Pendekatan ini menunjukkan perbedaan penting: PCA mencari arah variansi yang dapat memiliki kontribusi positif maupun negatif, sedangkan NMF membangun kombinasi aditif sehingga interpretasinya sering lebih mudah pada data yang secara alami tidak negatif.

2.6 Manifold Learning dengan t-SNE

t-SNE digunakan untuk memetakan data berdimensi tinggi ke ruang dua dimensi dengan mempertahankan kedekatan lokal antarsampel. Repository menggunakan dataset Digits yang berisi 1.797 sampel dan 64 fitur. Setelah transformasi, setiap sampel direpresentasikan oleh dua koordinat. Metode ini terutama berguna untuk eksplorasi visual, bukan sebagai pengganti umum untuk semua bentuk reduksi dimensi atau sebagai model yang langsung digunakan untuk memprediksi data baru.



Gambar 3. Visualisasi ulang t-SNE pada dataset Digits; label digit hanya digunakan untuk pewarnaan hasil.


Kelompok digit yang tampak terpisah menunjukkan bahwa struktur lokal pada data citra dapat muncul dengan jelas di ruang dua dimensi. Namun jarak antarkelompok yang jauh tidak selalu dapat ditafsirkan sebagai ukuran global yang presisi. Karena itu, hasil t-SNE paling tepat dipakai sebagai alat bantu visual untuk mengenali struktur, kedekatan, dan kemungkinan tumpang tindih antarsampel.

BAB III

CLUSTERING DAN EVALUASI

3.1 k-Means

k-Means membagi data ke dalam sejumlah kluster yang telah ditentukan sebelumnya. Prosesnya dilakukan secara iteratif dengan dua langkah utama: setiap titik ditempatkan pada pusat kluster terdekat, kemudian posisi pusat diperbarui berdasarkan rata-rata anggota kluster. Pada repository, data sintesis `make_blobs` digunakan bersama `KMeans(n_clusters=3, random_state=0)`. Setelah model terbentuk, `labels_` memberikan identitas kluster untuk setiap sampel.




Gambar 4. Visualisasi k-Means dengan tiga pusat kluster pada data sintesis.

Selain label kluster, kode juga menggunakan `kmeans.transform(X)` untuk mengubah setiap sampel menjadi jaraknya terhadap tiga pusat kluster. Pada data dengan 100 sampel, hasilnya memiliki bentuk 100×3 . Representasi jarak tersebut dapat dipahami sebagai bentuk vector quantization atau fitur baru yang menggambarkan kedekatan sampel terhadap setiap pusat. Keterbatasan utama k-Means adalah asumsi geometrinya: algoritma cenderung bekerja baik pada kluster yang relatif kompak dan berbentuk mendekati sferis, tetapi dapat kesulitan pada struktur melengkung atau densitas yang tidak seragam.

3.2 Agglomerative Clustering

Agglomerative Clustering membangun kluster secara hierarkis dari bawah ke atas. Pada awal proses, setiap sampel dianggap sebagai kelompok sendiri. Kelompok yang paling dekat kemudian digabungkan berulang kali sampai jumlah kluster yang diminta tercapai. Repository menggunakan `AgglomerativeClustering(n_clusters=3)` pada data sintetis yang sama sehingga hasilnya dapat dibandingkan dengan k-Means.

Untuk memperlihatkan struktur penggabungan secara lebih lengkap, kode membuat dataset kecil berisi 12 sampel dan menghitung linkage menggunakan metode ward dari SciPy. Hasil linkage memiliki 11 baris karena penggabungan terus dilakukan sampai seluruh sampel berada dalam satu struktur hierarkis. Informasi tersebut divisualisasikan sebagai dendrogram.



Gambar 5. Dendrogram yang memperlihatkan urutan penggabungan sampel pada hierarchical clustering.


Dendrogram membantu melihat pada tingkat jarak berapa dua kelompok digabungkan. Pemotongan dendrogram pada ketinggian tertentu dapat menghasilkan jumlah kluster yang berbeda. Dengan demikian, Agglomerative Clustering memberikan sudut pandang yang tidak hanya

berupa label akhir, tetapi juga hubungan bertingkat antarkelompok selama proses penggabungan.

3.3 DBSCAN

DBSCAN membentuk klaster berdasarkan kerapatan, bukan berdasarkan jumlah pusat yang harus ditentukan sejak awal. Dua parameter utamanya adalah ϵ , yaitu radius lingkungan suatu titik, dan min_samples , yaitu jumlah minimum sampel yang diperlukan agar suatu area dianggap cukup padat. Titik yang tidak dapat dimasukkan ke wilayah padat dapat diberi label -1 dan diperlakukan sebagai noise atau outlier.

Pada bagian demonstrasi sederhana, repository menggunakan DBSCAN($\epsilon=1.5$, $\text{min_samples}=3$) pada 12 sampel. Pada bagian evaluasi Two Moons, DBSCAN dijalankan setelah data distandardisasi. Contoh Two Moons penting karena bentuk dua kelompoknya melengkung; struktur seperti ini tidak cocok dengan asumsi pusat sferis k-Means, tetapi dapat diikuti oleh metode berbasis kepadatan.



Gambar 6. Hasil DBSCAN pada dataset Two Moons setelah StandardScaler.

Kelebihan DBSCAN adalah tidak memerlukan jumlah klaster sebagai masukan dan mampu mengenali noise. Sebaliknya, hasilnya sangat dipengaruhi oleh skala data serta pemilihan ϵ dan min_samples . Jika ϵ terlalu kecil, satu kelompok dapat terpecah menjadi banyak bagian atau

dianggap noise; jika terlalu besar, beberapa kelompok yang seharusnya berbeda dapat menyatu.

3.4 Evaluasi ARI dan Silhouette Score

Repository membandingkan tiga algoritma pada dataset Two Moons menggunakan dua sudut pandang evaluasi. Adjusted Rand Index (ARI) memakai label acuan dan mengukur kesesuaian antara pengelompokan hasil algoritma dengan pengelompokan sebenarnya. Nilai mendekati 1 menunjukkan kesesuaian yang sangat tinggi. Silhouette Score tidak memerlukan label acuan; metrik ini menilai apakah sampel lebih dekat dengan klasternya sendiri dibandingkan dengan klaster lain.

Algoritma	ARI	Silhouette Score	Interpretasi
k-Means	0,50	0,49	Klaster cukup kompak, tetapi bentuk Two Moons tidak terpisah sesuai label sebenarnya.
Agglomerative	0,61	0,46	Lebih sesuai terhadap label dibanding k-Means, tetapi masih belum mengikuti seluruh struktur lengkung.
DBSCAN	1,00	0,38	Mencocokkan label acuan dengan sangat baik walaupun Silhouette lebih rendah.

Hasil tersebut menunjukkan mengapa satu metrik tidak boleh dibaca tanpa konteks. DBSCAN memperoleh ARI 1,00 karena bentuk klaster yang ditemukannya sesuai dengan dua lengkungan pada data acuan. Namun Silhouette Score-nya lebih rendah daripada k-Means karena Silhouette cenderung menyukai klaster yang padat dan lebih konveks. Dengan kata lain,

skor internal yang lebih tinggi tidak selalu berarti struktur klaster lebih sesuai dengan pola sebenarnya.

Karena itu, ARI dan Silhouette perlu dibaca bersama konteks bentuk data, ketersediaan ground truth, dan tujuan analisis.

BAB IV

IMPLEMENTASI REPOSITORY DAN ANALISIS

4.1 Organisasi Program

Fungsi	Data/Metode	Keluaran Utama
demo_scaling_effects()	Breast Cancer + scaler + SVC	Skala fitur dan akurasi SVC.
demo_pca()	Breast Cancer + PCA(2)	569×30 menjadi 569×2 .
demo_nmf()	Sinyal sintetis + NMF(3)	Tiga komponen non-negatif.
demo_tsne()	Digits + t-SNE	1.797×64 menjadi representasi 2D.
demo_clustering()	Blobs + tiga metode clustering	Label, fitur jarak, linkage, dan membership.
demo_clustering_evaluation()	Two Moons + ARI/Silhouette	Perbandingan ARI dan Silhouette.

4.2 Hasil Utama

Program memperlihatkan tiga pelajaran utama: representasi data memengaruhi algoritma yang sensitif terhadap skala; PCA, NMF, dan t-SNE memiliki tujuan representasi yang berbeda; serta kualitas clustering tidak dapat dinilai hanya dari satu skor. Bentuk data dapat membuat metrik internal dan ground truth memberikan penilaian yang berbeda.

4.3 Analisis Kritis

Repository sudah memiliki pemisahan fungsi yang jelas dan `random_state` pada beberapa eksperimen sehingga lebih mudah direproduksi. Preamble membantu kompatibilitas dan konsistensi visualisasi. Keterbatasannya adalah ketergantungan pada `mglearn`, belum adanya

requirements yang mengunci versi pustaka, contoh NMF yang masih sintetis, serta parameter clustering yang belum dieksplorasi secara sistematis. Catatan ini penting agar eksperimen berikutnya lebih mudah diulang dan dibandingkan lintas lingkungan.

BAB V

PENUTUP

5.1 Kesimpulan

Implementasi Chapter 3 pada repository TugasML_CH3 menunjukkan bahwa unsupervised learning tidak dapat dipisahkan dari cara data direpresentasikan. Scaling berperan menyetarakan kontribusi fitur, PCA merangkum variasi ke komponen utama, NMF membentuk komponen aditif yang non-negatif, dan t-SNE membantu memperlihatkan struktur lokal data berdimensi tinggi. Pada tahap clustering, k-Means, Agglomerative Clustering, dan DBSCAN memberikan perilaku berbeda karena masing-masing menggunakan asumsi dan mekanisme pembentukan klaster yang berbeda.

Eksperimen Two Moons memperlihatkan bahwa DBSCAN dapat mengikuti bentuk klaster non-konveks dengan sangat baik, sedangkan k-Means dan Agglomerative menghasilkan kecocokan yang lebih rendah terhadap label acuan. Di sisi lain, Silhouette Score menunjukkan nilai yang tidak selalu sejalan dengan ARI. Hal tersebut menegaskan bahwa evaluasi clustering harus dibaca berdasarkan bentuk data dan tujuan analisis, bukan hanya berdasarkan satu angka.

5.2 Saran

Pengembangan tugas selanjutnya dapat dilakukan dengan menambahkan requirements.txt atau environment file agar versi pustaka tercatat, menyimpan output eksperimen secara konsisten, serta melakukan eksplorasi parameter seperti jumlah klaster, eps, min_samples, dan jumlah komponen. Pengujian juga dapat diperluas ke dataset lain dengan karakter distribusi yang berbeda. Untuk laporan eksperimen yang lebih kuat, setiap hasil sebaiknya mencatat versi pustaka, parameter, random seed, serta alasan pemilihan metrik sehingga proses analisis dapat diulang dan dibandingkan dengan lebih mudah.

DAFTAR PUSTAKA

- Müller, A. C., & Guido, S. (2016). Introduction to Machine Learning with Python: A Guide for Data Scientists. O'Reilly Media.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Dokumentasi tugas pada README.md, chapter3_unsupervised_learning.py, preamble.py, dan notebook 03-unsupervised-learning.ipynb dalam repository TugasML_CH3, diakses September 2026.